

Hol die OMA aus der Socke – eine Leuchtturmaufgabe

REIMUND VEHLING, HANNOVER

Zusammenfassung: Ein einfaches Zufallsexperiment kann zu weitreichenden stochastischen Fragestellungen führen. Der Beitrag zeigt dies am Beispiel der Aufgabe „Hol die OMA aus der Socke“. Bereits im Anfangsunterricht ermöglicht die Situation einen handlungsorientierten Zugang zu Zufall, Reihenfolgen und ersten Modellierungsfragen. Zugleich eignet sie sich für weiterführende Betrachtungen: Je nachdem, wie das Ziehen der Buchstaben interpretiert wird, entstehen unterschiedliche Zufallsprozesse und damit unterschiedliche Verteilungen der Wartezeit bis zum ersten Auftreten von OMA. Vorgestellt werden vier Modellierungen und die jeweilige Rolle von Realexperiment, Simulation, Zustandsgraphen, Rekursionen, GeoGebra, Python und weiterführenden mathematischen Methoden. Die ergänzenden GeoGebra- und Python-Dateien sowie vertiefende Materialien sind online verfügbar (Vehling, 2026).

1 Vom Ausgangsproblem zur Modellierungsfrage

Ausgangspunkt des Beitrags ist das von Riemer beschriebene Zufallsexperiment „Hol die OMA aus der Socke“ (siehe Riemer, 2023, S. 14). Es gehört zu den einfachen stochastischen Situationen, die schon mit wenigen Materialien einen reichhaltigen mathematischen Lernprozess anstoßen können. In einer Socke liegen die Buchstaben O, M und A. Sie werden wie beim Scrabble-Spiel gezogen; Ziel ist es, die Reihenfolge OMA zu erhalten.

Der besondere didaktische Wert der Aufgabe liegt darin, dass sie zunächst unmittelbar zugänglich ist, zugleich aber viele zentrale Denkweisen der Stochastik berührt. Das Experiment kann real durchgeführt, sprachlich beschrieben, zeichnerisch dargestellt, simuliert und theoretisch untersucht werden. Dadurch entsteht früh die Möglichkeit, zwischen der realen Handlung, einer Modellannahme und einer mathematischen Beschreibung zu unterscheiden.

Der Begriff Leuchtturmaufgabe wird hier in einem didaktischen Sinn verstanden. Gemeint ist eine Aufgabe, die weit über eine einzelne Rechenfrage hinausweist: Sie ist im Einstieg einfach und anschaulich, leuchtet aber zugleich einen größeren mathematischen Raum aus. An ihr lassen sich unterschiedliche Modellannahmen, Simulationen, Verteilungen, Kenngrößen, Zustandsgraphen, Rekursionen und weiterführende theoretische Zugänge miteinander verbinden. Gerade

darin liegt ihr besonderer Wert: Die Aufgabe bleibt für Lernende zugänglich, öffnet den Blick auf zentrale Denkweisen der Stochastik und erweist sich zugleich als Träger weitreichender mathematischer Strukturen, die im weiteren Verlauf schrittweise freigelegt werden.

1.1 Drei Modellierungen im Vergleich

Die drei im Folgenden betrachteten Modellierungen werden nicht als voneinander unabhängige Einzelfälle verstanden, sondern als Varianten desselben Ausgangsproblems. Im Mittelpunkt steht damit nicht nur die Berechnung einzelner Wahrscheinlichkeiten oder Kenngrößen, sondern die Frage, wie sich unterschiedliche Modellannahmen auf die mathematische Struktur des Problems auswirken.

Gerade diese vergleichende Perspektive ist für den Unterricht bedeutsam: Kleine Änderungen der Spielregeln führen zu anderen stochastischen Modellen. So kann etwa die Entscheidung, ob ein gezogener Buchstabe wieder in die Socke zurückgelegt wird oder nicht, die Unabhängigkeit der Versuche, die Form der Verteilung und die Möglichkeiten der Berechnung wesentlich verändern. Damit verschiebt sich der Blick von der bloßen Durchführung einzelner Rechnungen hin zur Reflexion über Modellierungsentscheidungen. Die digitale Umsetzung unterstützt diesen Perspektivwechsel: Simulationen liefern Daten, GeoGebra macht Verteilungen und Zusammenhänge sichtbar, Tabellenkalkulationen ermöglichen rekursive Berechnungen, und CAS- oder Python-Werkzeuge können zur exakten beziehungsweise näherungsweise Bestimmung von Kenngrößen eingesetzt werden.

In diesem Sinne werden drei Modellierungen ausführlich behandelt; eine weitere Variante wird in den ergänzenden Materialien auf GitHub dokumentiert. Im Vordergrund steht, welche mathematischen und didaktischen Einsichten die jeweilige Modellierung ermöglicht.

Der Lernweg folgt dabei jeweils in fünf Schritten:

1. Mit Realexperimenten beginnen und Erwartungen einfordern.
2. Den Zufallsprozess in GeoGebra sichtbar machen.
3. Daten sammeln und verschiedene Darstellungen benutzen.
4. Simulationen wissenschaftlich nutzen.

5. Theoretisch modellieren und prüfen.

Im ersten Schritt wird aus dem einmaligen Spiel ein erster Modellierungsimpuls: ein überschaubares Wartezeitproblem mit abzählbar unendlicher Ergebnismenge. Von hier aus kann die Aufgabe weiter geöffnet werden. Ein zweiter Modellierungsimpuls entsteht, wenn die Ziehungsregel selbst verändert wird: Was geschieht, wenn nach jeder Ziehung zurückgelegt wird? Was geschieht, wenn passende Buchstaben behalten werden? Oder was geschieht, wenn die Buchstaben als fortlaufender zufälliger Strom erzeugt werden?

In diesem Sinn besitzt die Aufgabe auch den Charakter einer Blütenaufgabe. Aus einem einfachen Kernproblem entfalten sich mehrere mathematisch unterschiedlich anspruchsvolle Modellierungswege.

2 Digitale Werkzeuge im Modellierungsprozess

Die Simulationen und Berechnungen in diesem Beitrag werden nicht als Selbstzweck verstanden. GeoGebra, Python, Tabellenkalkulation und CAS übernehmen unterschiedliche Funktionen im Modellierungsprozess. Entscheidend ist daher nicht die Frage, welches Werkzeug überlegen ist, sondern welches Werkzeug an welcher Stelle welche didaktische Funktion erfüllt.

GeoGebra eignet sich besonders dazu, Zufallsprozesse sichtbar zu machen. Einzelne Realisationen können entschleunigt betrachtet, Daten schrittweise gesammelt und grafisch dargestellt werden. Die Umsetzung sollte dabei das jeweilige Modell möglichst unmittelbar abbilden. Insbesondere sollen keine zusätzlichen Annahmen in der technischen Realisierung versteckt werden. Wird etwa in GeoGebra zunächst eine Liste von Zufallsziehungen erzeugt, so ist deren Länge lediglich ein technischer Parameter der Simulation. Eine Festlegung wie $n = 200$ gehört nicht zum stochastischen Modell, sondern beschreibt nur, wie weit GeoGebra die Folge zunächst erzeugt.

Python kann - anders als GeoGebra - einen Prozess direkt durch Kontrollstrukturen wie `while`- oder `for`-Schleifen beschreiben und damit beispielsweise so lange simulieren, bis eine Abbruchbedingung erfüllt ist. GeoGebra arbeitet im hier gewählten schulnahen Zugang dagegen vor allem mit erzeugten Objekten: Listen, Teillisten, Tabellenspalten und grafischen Darstellungen. Dieser Unterschied ist kein Nachteil, sondern macht verschiedene Sichtweisen auf das Modell sichtbar.

Python übernimmt im Beitrag vor allem die Rolle eines wissenschaftlichen Simulationswerkzeugs. Große Simulationszahlen, kontrollierbare Zufallszahlen durch

einen Seed und der Vergleich relativer Häufigkeiten mit theoretischen Modellwerten machen sichtbar, dass Simulationen Daten liefern, aber nicht selbst das Modell sind. Die Simulation kann Vermutungen stützen, Abweichungen einordnen und die Streuung erfahrbar machen; die Wahrscheinlichkeiten müssen jedoch aus dem Modell begründet werden.

Vor jeder Simulation steht deshalb zunächst das Vermuten. Welche Wartezeiten erscheinen typisch? Wie groß könnte der Erwartungswert sein? Ist mit einer großen Streuung zu rechnen? Gerade bei Wartezeiten ist diese zweite Frage zentral: Ein Erwartungswert ist ohne Kenntnis der Streuung nur bedingt aussagekräftig. Seltene, aber sehr große Wartezeiten können den Mittelwert deutlich beeinflussen.

2.1 ChatGPT als Werkzeug im Arbeitsprozess

Auch ChatGPT wurde im Entstehungsprozess dieses Beitrags als digitales Werkzeug genutzt. Die Python-Programme und die damit erzeugten Grafiken wurden mithilfe von ChatGPT entwickelt, überarbeitet und an die fachlichen sowie gestalterischen Vorgaben angepasst. Entscheidend war dabei nicht eine automatische Erzeugung von Ergebnissen, sondern ein dialogischer Arbeitsprozess: Die mathematische Modellierung, die Wahl der Darstellungsform, die Vorgabe reproduzierbarer Simulationen, die fachliche Prüfung der Programme und die abschließende Auswahl der Abbildungen blieben beim Autor.

Gerade bei Simulationen ist eine solche Steuerung wesentlich. Vorgegeben wurden unter anderem feste Seeds, große Simulationszahlen, der Vergleich relativer Häufigkeiten mit exakten Modellwahrscheinlichkeiten sowie eine Darstellung auf Publikationsniveau. So wurden etwa keine Histogramme verwendet, sondern diskrete Wahrscheinlichkeitsverteilungen, in denen simulierte relative Häufigkeiten und theoretische Modellwerte bewusst gegenübergestellt werden. Konfidenzintervalle machen zusätzlich sichtbar, welche Abweichungen bei endlichen Stichproben als zufällige Schwankungen zu erwarten sind.

Der Einsatz von ChatGPT ersetzt damit weder die mathematische Modellierung noch die fachliche Kontrolle. Er kann aber helfen, Programme schneller zu entwerfen, Darstellungen zu variieren, Fehler zu finden und grafische Standards konsequent umzusetzen. Damit wird auch an dieser Stelle deutlich: Digitale Werkzeuge führen nicht automatisch zu mathematischer Einsicht. Entscheidend bleibt die reflektierte Nutzung durch die Person vor der Tastatur.

2.2 GeoGebra-Umsetzungen als endliche Arbeitsobjekte

In den folgenden GeoGebra-Umsetzungen wird der Zufallsprozess häufig dadurch realisiert, dass zunächst eine ausreichend lange Liste von Zufallsziehungen erzeugt und anschließend ausgewertet wird. Diese Liste ist ein technisches Arbeitsobjekt der Simulation und nicht Teil des stochastischen Modells. Eine Festlegung wie $n = 200$ oder allgemeiner eine obere Grenze N beschreibt nur, wie weit GeoGebra den Prozess zunächst erzeugt oder berechnet. Das mathematische Modell lautet dagegen weiterhin: Es wird so lange gezogen beziehungsweise erzeugt, bis die im Modell festgelegte Bedingung erfüllt ist.

Gerade diese Unterscheidung ist didaktisch wichtig. GeoGebra soll das jeweilige Modell möglichst unmittelbar abbilden, ohne zusätzliche Annahmen in der technischen Umsetzung zu verstecken. Für die einzelnen Modellierungen muss daher jeweils nur noch geklärt werden, welche Liste erzeugt wird, welche Bedeutung ihre Einträge haben und wie aus dieser Liste die Wartezeit T bestimmt wird.

3 Modell 1: Vom einmaligen Spiel zum Wartezeitproblem

Wird das Spiel mehrfach durchgeführt, entsteht sehr schnell eine naheliegende Frage: Wie lange muss man wohl im Durchschnitt warten, bis erstmals die Buchstabenfolge OMA gezogen wird? Diese Frage ist zunächst noch nicht mathematisch präzise formuliert, besitzt aber eine hohe intuitive Plausibilität. Sie greift eine Erfahrung auf, die Schülerinnen und Schüler beim wiederholten Spielen unmittelbar machen: Manchmal tritt OMA früh auf, manchmal muss man deutlich länger warten.

Die Schülerinnen und Schüler können Vermutungen äußern: Wie viele Versuche werden im Mittel nötig sein? Welche Werte erscheinen typisch? Können sehr lange Wartezeiten auftreten? Und wie stark werden die Ergebnisse verschiedener Gruppen voneinander abweichen? Diese Vermutungen bilden den Ausgangspunkt für die anschließende Simulation.

Mathematisch führt diese Variation auf ein Wartezeitproblem. Jeder einzelne Versuch besteht weiterhin darin, ohne Zurücklegen drei Buchstaben aus der Socke zu ziehen. Gewonnen ist ein Versuch genau dann, wenn die Folge OMA entsteht. Wird das Spiel so lange wiederholt, bis erstmals ein Treffer auftritt, so erhält man eine geometrisch verteilte Wartezeit. Dieses erste Wartezeitmodell bleibt damit nahe am Ausgangsproblem und ist zugleich theoretisch gut zugänglich.

3.1 Simulation in GeoGebra

Die erste Umsetzung in Listing 1 ist bewusst einfach gehalten.

```
Socke = {"A", "M", "O"}
Zielwort = {"O", "M", "A"}
n=200
Ziehungen = Folge(Stichprobe(Socke, 3,
                             false), i, 1, n)
Wartezeit = IndexVon(Zielwort, Ziehungen)
```

Listing 1: GeoGebra-Befehle für einen Durchlauf von Modell 1

Entscheidend ist nicht eine möglichst komplexe Programmierung, sondern die klare Trennung der beteiligten Objekte: Socke beschreibt den Inhalt der Socke, Zielwort beschreibt die gesuchte Reihenfolge. Die Liste {"A", "M", "O"} ist dabei lexikografisch angeordnet und steht für den Vorrat der möglichen Buchstaben. Sie ist bewusst nicht identisch mit dem Zielwort {"O", "M", "A"}. Erst der Befehl IndexVon(Zielwort, Ziehungen) prüft, an welcher Stelle die gesuchte Folge erstmals in der Liste der erzeugten Ziehungen auftritt.

Wichtig ist dabei die Bedeutung der geschweiften Klammern in GeoGebra. Sie bezeichnen hier eine Liste und keine Menge im mathematischen Sinn. Die Reihenfolge der Einträge bleibt erhalten, und auch Mehrfachvorkommen wären möglich. Gerade deshalb eignet sich diese Schreibweise, um den Inhalt einer Socke flexibel zu modellieren.

Diese Simulation verfolgt zunächst ein spielnahes Ziel. Eine Darstellung des Trefferindikators über mehrere Spielrunden macht sichtbar, dass Treffer unregelmäßig auftreten: Zwischen zwei Treffern können kurze, aber auch deutlich längere Abstände liegen. Diese Darstellung dient nicht der exakten Berechnung, sondern dem Aufbau einer Vorstellung davon, was eine Wartezeit als Zufallsgröße bedeutet. Auch lässt sich die Liste Ziehungen händisch bearbeiten und so Wartezeiten ohne weiteren Computereinsatz ermitteln.

In einem zweiten Schritt können mithilfe zweier Schaltflächen viele Realisationen Stück für Stück gesammelt und grafisch dargestellt werden. GeoGebra eignet sich hier besonders, um die entstehenden Daten als Dotplot und Boxplot gemeinsam sichtbar zu machen. Der Dotplot zeigt die diskrete Struktur der Wartezeiten und die Häufung einzelner Werte. Der Boxplot verdichtet dieselben Daten auf wenige Kenngrößen. Gerade aus der gemeinsamen Darstellung lässt sich herausarbeiten, welche Informationen sichtbar werden und welche durch die Verdichtung verdeckt bleiben.

Abbildung 1 zeigt eine typische GeoGebra-Darstellung der gesammelten Daten. Das Achsenlabel n steht hier für die Wartezeit, also die Nummer der Spielrunde, in der erstmals OMA gezogen wurde. Die Datenanzahl beträgt $m = 100$.




Abb. 1: Dotplot und Boxplot von 100 simulierten Wartezeiten. Der Punkt im Boxplot markiert den empirischen Mittelwert.

Der Dotplot macht die diskrete Struktur der Daten sichtbar: Viele Treffer treten bereits nach wenigen Spielrunden auf, zugleich gibt es einzelne deutlich größere Wartezeiten. Der Boxplot verdichtet dieselben Daten auf wenige Kenngrößen. Dadurch entsteht ein kompaktes Bild, zugleich gehen aber Informationen über die Häufigkeiten einzelner Werte verloren.

Der zusätzlich eingezeichnete Punkt im Boxplot markiert den empirischen Mittelwert. Er liegt rechts vom Median. Dies ist typisch für eine rechtsschiefe Verteilung: Seltene, aber große Wartezeiten ziehen den Mittelwert nach rechts. Gerade deshalb sollte der Boxplot hier nicht isoliert betrachtet werden. Erst im Zusammenspiel mit dem Dotplot wird deutlich, welche Informationen die Darstellung liefert und welche sie verdeckt.

Der Dotplot macht sichtbar, dass frühe Treffer, etwa bei $T = 3$, durchaus eine wichtige Rolle spielen. Im Boxplot kann derselbe Wert jedoch außerhalb der Box liegen. Der Boxplot ist daher nicht falsch, aber ohne den Dotplot leicht missverständlich. Zudem zeigt sich bei der rechtsschiefen Verteilung typischerweise

$$\text{Median}(T) < \bar{T}.$$

Der Mittelwert $\bar{T}$ wird durch seltene, aber große Wartezeiten nach rechts gezogen.

Damit wird an einem einfachen Beispiel eine zentrale Einsicht vorbereitet: Simulationsergebnisse sind Daten und noch nicht das Modell. Kleine Stichproben können anschauliche, aber noch nicht belastbare Bilder liefern. Besonders Schätzwerte für die Streuung reagieren empfindlich auf seltene große Wartezeiten; für stabile Aussagen sind daher sehr viele Simulationen nötig,

oft erst in der Größenordnung von mehreren tausend bis etwa 10 000 Durchläufen.

Dafür eignet sich Python, das hier eine andere Funktion als GeoGebra übernimmt. Hier steht nicht mehr das Entschleunigen einzelner Realisationen im Vordergrund, sondern die reproduzierbare Simulation einer großen Anzahl von Durchläufen. Die simulierte Verteilung kann mit dem exakten Modell verglichen werden; Konfidenzintervalle zeigen auf, in welchem Bereich zufällige Abweichungen der relativen Häufigkeiten zu erwarten sind. Bedeutsam ist dabei nicht nur das Ergebnis, sondern der Weg zur Formel. Die Schülerinnen und Schüler können die Verteilungsformel selbst aufstellen. Die anschließenden Umformungen und Berechnungen der Kenngrößen können dann sinnvoll an ein CAS ausgelagert werden. Die mathematische Leistung liegt zunächst darin, das passende Modell zu erkennen und die Formeln für $\mathbb{P}(K = k)$, $\mathbb{E}(K)$ und $\mathbb{V}(K)$ aufzustellen.

3.2 Herleitung der Verteilung

Für die geometrische Wartezeit lässt sich die Rechnung auch allgemein mit der Trefferwahrscheinlichkeit p durchführen. Der Mehrwert zeigt sich darin, dass Strukturen sichtbar werden, die bei der bloßen Einsetzung von $p = \frac{1}{6}$ verborgen bleiben.

Die Zufallsgröße K bezeichne die Anzahl der Spielrunden bis zum ersten Treffer. Da die Spielrunden unabhängig voneinander wiederholt werden, erhält man

$$\mathbb{P}_p(K = k) = (1 - p)^{k-1} p, \quad k = 1, 2, 3, \dots$$

Für $p = \mathbb{P}(\text{OMA}) = \frac{1}{6}$ ergibt sich daraus das erste Wartezeitmodell.

Bei einer Zufallsgröße mit abzählbar unendlicher Wertemenge genügt es jedoch nicht, nur eine Formel für $\mathbb{P}_p(K = k)$ anzugeben. Es muss auch geprüft werden, ob die gesamte Wahrscheinlichkeitsmasse den Wert 1 besitzt:

$$\sum_{k=1}^{\infty} (1 - p)^{k-1} p = 1.$$

Dieser Nachweis kann im schulischen Kontext sinnvoll mit einem CAS erfolgen. Damit wird zugleich deutlich: Eine aus dem Modell gewonnene Formel muss auf ihre Gültigkeit als Wahrscheinlichkeitsverteilung überprüft werden.

Aus derselben Verteilung ergeben sich die Kenngrößen

$$\mathbb{E}_p(K) = \sum_{k=1}^{\infty} k (1 - p)^{k-1} p = \frac{1}{p}$$

und

$$\mathbb{V}_p(K) = \sum_{k=1}^{\infty} \left(k - \frac{1}{p}\right)^2 (1-p)^{k-1} p = \frac{1-p}{p^2}.$$

Die zentrale Leistung der Schülerinnen und Schüler liegt dabei zunächst im Aufstellen der Verteilung und der zugehörigen Summen. Die anschließende Auswertung der unendlichen Reihen kann an ein CAS ausgelagert werden. Gerade die allgemeine Rechnung mit p zeigt den Mehrwert dieses Werkzeugs: Es liefert nicht nur einzelne Zahlenwerte, sondern zeigt die Abhängigkeit der Kenngrößen von der Trefferwahrscheinlichkeit.

Damit wird sichtbar: Je kleiner die Trefferwahrscheinlichkeit ist, desto größer sind mittlere Wartezeit und Varianz. Der Erwartungswert $E_p(K) = 1/p$ lässt sich unmittelbar interpretieren: Bei einer Trefferwahrscheinlichkeit von p werden im Mittel $1/p$ Versuche bis zum ersten Treffer benötigt. Die Formel für die Varianz ist dagegen deutlich weniger offensichtlich.

Für $p := \mathbb{P}(\text{OMA}) = \frac{1}{6}$ folgt schließlich

$$\mathbb{E}(K) = 6, \quad \mathbb{V}(K) = 30.$$

4 Zwei weitere Modellierungen

Das erste Wartezeitproblem bleibt noch sehr nahe am ursprünglichen Spiel: Ein Versuch besteht weiterhin aus einer Ziehung ohne Zurücklegen; nur die Wiederholung bis zum ersten Treffer wird betrachtet. Von hier aus kann die Aufgabe weiter geöffnet werden. Der nächste Modellierungsimpuls entsteht, wenn nicht nur die Wiederholung des Spiels, sondern die Ziehungsregel selbst verändert wird.

Im Folgenden werden zwei weitere Modellierungen ausführlich betrachtet.

1. Bei Modell 2 (Sammelmodell) wird ein passender Buchstabe aus der Socke entfernt. Die Zusammensetzung der Socke verändert sich also während des Prozesses.
2. Bei Modell 3 (Strommodell) wird ein fortlaufender Strom unabhängiger Buchstaben betrachtet. Entscheidend ist hier nicht das Sammeln der Buchstaben, sondern das erste Auftreten der zusammenhängenden Folge OMA.

Diese beiden Modellierungen führen zu einer Zufallsgröße T , der Wartezeit bis zum ersten erfolgreichen Auftreten von OMA. Gemeinsam ist ihnen, dass T die Werte

$$3, 4, 5, \dots$$

annehmen kann. Die Unterschiede liegen in den Modellannahmen und zeigen sich in den Verteilungen, Erwartungswerten und Streuungen.

5 Modell 2: Passendes bleibt liegen

Im Sammelmodell wird ein passender Buchstabe nicht mehr zurückgelegt. Dadurch ändern sich die Trefferwahrscheinlichkeiten:

$$\frac{1}{3}, \quad \frac{1}{2}, \quad 1.$$

Nach dem ersten passenden Buchstaben befinden sich nur noch zwei Buchstaben in der Socke, nach dem zweiten passenden Buchstaben nur noch einer.

Die Zusammensetzung der Socke verändert sich während des Zufallsexperiments. Sobald der gesuchte Buchstabe gezogen wurde, wird er aus der Socke entfernt. Genau hierin unterscheidet sich die auf GitHub dokumentierte Modellierung. Dort wird Passendes notiert und wieder zurückgelegt.

5.1 Simulation in GeoGebra

Die Simulation (siehe Listing 2) muss für diesen Fall die veränderte Socke berücksichtigen. Zunächst wird so lange aus Socke1 gezogen, bis ein O erscheint. Danach wird das O entfernt. Anschließend wird aus Socke2 gezogen, bis ein M erscheint. Danach bleibt nur noch A übrig.

```
Socke1 = {"A", "M", "O"}
n = 200
z1 = Stichprobe(Socke1, n, true)
Pos0 = IndexVon("O", z1)
Socke2 = {"A", "M"}
z2 = Stichprobe(Socke2, n, true)
PosM = IndexVon("M", z2)
Wartezeit = Pos0 + PosM + 1
```

Listing 2: GeoGebra-Befehle für einen Durchlauf von Modell 2

In dieser Modellierung wird die Unabhängigkeit der einzelnen Suchabschnitte implizit verwendet: Nach dem Entfernen eines passenden Buchstabens beginnt der nächste Abschnitt als neuer Zufallsprozess mit der veränderten Socke. Die konkrete vorherige Ziehungsfolge spielt für diesen neuen Abschnitt keine Rolle mehr; entscheidend ist nur, welcher Zustand der Socke erreicht wurde.

Damit wird die Gesamtzahl der Ziehungen als Summe von Wartezeiten modelliert: $T = T_O + T_M + 1$. Dabei beschreibt T_O die Wartezeit bis zum ersten O bei einer Socke mit drei Buchstaben, T_M die Wartezeit bis zum

ersten M bei einer Socke mit zwei Buchstaben. Der letzte Summand ist 1, da nach dem Entfernen von O und M nur noch der Buchstabe A in der Socke liegt.

5.2 Herleitung aus dem Zustandsgraphen

Der Zustandsgraph (s. Abb. 2) lässt sich direkt in eine Summe übersetzen.




Abb. 2: Zustandsgraph für Modell 2

Für $T = n$ muss ein Weg durch den Zustandsgraphen zunächst eine gewisse Anzahl von Schleifen im Startzustand S durchlaufen, dann erstmals in den Zustand O wechseln, dort möglicherweise weitere Schleifen durchlaufen, anschließend in den Zustand OM wechseln und schließlich im nächsten Schritt OMA erreichen. Die zu verschiedenen Werten von i gehörenden Wege schließen sich gegenseitig aus. Daher erhält man für $n \geq 3$

$$\mathbb{P}(T = n) = \sum_{i=1}^{n-2} \left(\frac{2}{3}\right)^{i-1} \cdot \frac{1}{3} \cdot \left(\frac{1}{2}\right)^{n-2-i} \cdot \frac{1}{2} \cdot 1. \quad (1)$$

Die Formel entsteht also, indem man alle möglichen Wege durch den Zustandsgraphen, die nach genau n Schritten erstmals in OMA enden, nach dem ersten Übergang $S \rightarrow O$ ordnet und ihre Wahrscheinlichkeiten addiert.

Die Vereinfachung der Summe in (1) kann anschließend mit einem CAS erfolgen:

$$\mathbb{P}(T = n) = \left(\frac{2}{3}\right)^{n-2} - \left(\frac{1}{2}\right)^{n-2}.$$

Der Einsatz eines CAS hat an dieser Stelle nicht die Funktion, die Modellierung zu ersetzen. Die zentrale mathematische Arbeit besteht im Aufstellen des Zustandsgraphen und in seiner Übersetzung in eine Summe. Das CAS entlastet anschließend von algebraischen Umformungen und macht eine Struktur sichtbar, die in der Summendarstellung weniger deutlich hervortritt: Die Verteilung lässt sich als Differenz zweier geometrisch abnehmender Terme beschreiben.

5.3 Kenngrößen in GeoGebra-CAS

Aus der in Abschnitt 3.2 dargestellten Beziehung $\mathbb{E}_p(K) = 1/p$ ergibt sich hier unmittelbar die Vermutung, dass die mittlere Wartezeit $3 + 2 + 1 = 6$

beträgt. GeoGebra-CAS kann wieder benutzt werden, um die exakten Werte für die Kenngrößen zu ermitteln. Es gilt

$$\mathbb{E}(T) = 6, \quad \mathbb{V}(T) = 8.$$

Abbildung 3 zeigt den Vergleich zwischen den simulierten Daten und den exakten Modellwahrscheinlichkeiten.




Abb. 3: Vergleich der mit Python simulierten und der exakten Verteilung für Modell 2.

Die relativen Häufigkeiten $H(T = n)$ entstehen aus der Simulation (graue Säulen); die Werte $\mathbb{P}(T = n)$ ergeben sich aus dem zuvor entwickelten Modell (schwarze Punkte). Die als senkrechte Intervalle eingezeichneten 95%-WILSON-Konfidenzintervalle machen sichtbar, welche Abweichungen bei einer Stichprobe dieser Größe noch als erwartbare Zufallsschwankungen angesehen werden können.

Es wurden $N = 10\,000$ Durchläufe simuliert. Auf zwei Nachkommastellen gerundet ergeben sich die Schätzwerte $\widehat{\mathbb{E}}(T) = 6,01$ und $\widehat{\mathbb{V}}(T) = 7,85$. Die Simulation ist im zugehörigen Python-Notebook reproduzierbar dokumentiert.

6 Modell 3: die Strommaschine

Dieses Modell beschreibt das Experiment als Strommaschine. In jedem Schritt wird unabhängig ein Buchstabe aus $\{A, M, O\}$ erzeugt. Die Maschine liest den entstehenden Buchstabenstrom und wartet darauf, dass zum ersten Mal die Folge OMA erscheint. Anders als in den beiden Sammelmodellen werden passende Buchstaben also nicht dauerhaft festgehalten. Nach jedem neuen Buchstaben zählt nur, welcher Anfang der gesuchten Folge OMA gerade am Ende des gelesenen Stroms steht.

6.1 Simulation in GeoGebra

Schülerinnen und Schüler können zunächst einzelne Zufallsfolgen untersuchen, Trefferzeiten sammeln, den zentralen Unterschied zu den beiden anderen Modellen entdecken sowie eine empirische Verteilung

erzeugen. Dadurch entsteht ein echtes Bedürfnis nach mathematischer Erklärung.

Die Umsetzung geschieht wieder listenorientiert (s. Listing 3): Zunächst wird eine endliche Zufallsfolge erzeugt, anschließend wird diese Folge nach dem Muster OMA durchsucht. Dabei ist Start die Anfangsstelle des ersten Auftretens von OMA, während Stelle die Stelle des abschließenden A ist. Die Realisationen der Zufallsgröße T werden also durch die Variable Stelle repräsentiert.

```
n = 200
L1 = {"A", "M", "O"}
L2 = Stichprobe(L1, n, true)
L3 = Folge(Teilliste(L2, i, i+2) ==
           {"O", "M", "A"}, i, 1, n-2)
Start = IndexVon(true, L3)
Stelle = Start + 2
```

Listing 3: GeoGebra-Befehle für einen Durchlauf von Modell 3

Die Befehlsfolge in GeoGebra zeigt deutlich: Gesucht ist die Stelle, an der OMA zum ersten Mal vollständig erscheint. Im Unterschied zu den Sammelmodellen können begonnene Muster wieder verloren gehen. Genau das wird im Zustandsgraphen (s. Abb. 4) sichtbar. Die zentrale Idee einer Rekursion wird hier schon sichtbar.

Die Zustände sind S, O, OM und OMA. Dabei bedeutet S, dass am Ende des bisher gelesenen Stroms kein Anfang des Wortes OMA steht. Der Zustand O bedeutet, dass zuletzt ein O gelesen wurde und damit ein möglicher Anfang von OMA vorliegt. Der Zustand OM bedeutet, dass die letzten beiden Buchstaben bereits die Anfangsfolge OM bilden. Der Zustand OMA ist der absorbierende Trefferzustand.




Abb. 4: Zustandsgraph für Modell 3

6.2 Ein schulnaher Weg zur Rekursion

Wir betrachten zunächst Ziehungsfolgen, in denen bis einschließlich zum 9. Zug keine Buchstabenfolge OMA erschienen ist. Die Wahrscheinlichkeit dafür bezeichnen wir mit $S(9)$. Unter diesen bis Zug 9 trefferfreien Folgen kann OMA im nächsten Schritt nur

dann erstmals auftreten, wenn die drei letzten Züge die Folge OMA bilden. Da OMA keine Selbstüberlappung besitzt, muss dazu bis zum 7. Zug noch kein Treffer vorliegen. Wegen der Unabhängigkeit der Ziehungen folgt

$$\mathbb{P}(T = 10) = S(7) \cdot \mathbb{P}(\text{OMA}) = S(7) \cdot \frac{1}{27}. \quad (2)$$

Das Beispiel zeigt den allgemeinen Zusammenhang. Damit $T = n$ gilt, muss OMA genau mit der n -ten Ziehung erstmals vollständig sein. Die letzten drei Ziehungen müssen also OMA ergeben, während in den ersten $n-3$ Ziehungen noch kein OMA aufgetreten sein darf. Daher gilt allgemein nach (2)

$$P(T = n) = S(n-3) \cdot \frac{1}{27}.$$

Sind also die früheren Werte der Folge S bekannt, insbesondere $S(n-3)$, kann daraus sofort $P(T = n)$ bestimmt werden. Für kleine Werte von n können dafür die Wahrscheinlichkeiten noch direkt ermittelt werden. Mit wachsendem n wird dies jedoch schnell unübersichtlich. Genau hier kommt die Rekursion ins Spiel. Um $S(n)$ zu erhalten, muss man von $S(n-1)$ die Wahrscheinlichkeit $\mathbb{P}(T = n)$ subtrahieren, also $S(n-3) \cdot \mathbb{P}(\text{OMA})$. Dies führt mit $\mathbb{P}(\text{OMA}) = \frac{1}{27}$ direkt zur Rekursionsgleichung

$$S(n) = S(n-1) - S(n-3) \cdot \frac{1}{27}.$$

Von dieser Gleichung sind zunächst nur die Startwerte

$$S(0) = S(1) = S(2) = 1$$

bekannt. Damit lassen sich nun aber Schritt für Schritt die Werte für $S(n)$ ermitteln. Hierfür eignet sich besonders der Einsatz einer Tabellenkalkulation, die GeoGebra auch zur Verfügung stellt. Die Rekursionsformel muss dabei nur einmal eingegeben und anschließend nach unten kopiert werden (s. Abb. 5).

	A	B	C	D
1	n	S(n)	P(T=n)	E_N(T)
2	0	1	0	A2 C2
3	A2 + 1	1	0	A3 C3 + D2
4	A3 + 1	1	0	A4 C4 + D2
5	A4 + 1	B4 - 1 / 27 B2	1 / 27 B2	A5 C5 + D4
6	A5 + 1	B5 - 1 / 27 B3	1 / 27 B3	A6 C6 + D5

Abb. 5: Umsetzung der Rekursion mit der Tabellenkalkulation von GeoGebra

Dabei wird in einer Spalte die Größe $S(n)$ berechnet, also die Wahrscheinlichkeit, dass das Wort OMA nach

n Ziehungen noch nicht vollständig erschienen ist. Damit ist zugleich $S(n) = \mathbb{P}(T > n)$.

Die so berechneten Werte $\mathbb{P}(T = n)$ sind keine simulierten Daten, sondern exakte Modellwerte für den jeweils berechneten endlichen Bereich. In der Tabellenkalkulation kann daraus schrittweise die Partialsumme

$$\mathbb{E}_N(T) = \sum_{n=3}^N n \cdot \mathbb{P}(T = n)$$

gebildet werden. Die zusätzliche Spalte macht sichtbar, wie sich diese Partialsumme mit wachsendem n dem exakten Erwartungswert nähert. Entsprechend kann aus den bis N berechneten Wahrscheinlichkeiten auch ein Näherungswert für die Varianz gebildet werden:

$$V_N(T) = \sum_{n=3}^N (n - \mathbb{E}_N(T))^2 \cdot \mathbb{P}(T = n).$$

In GeoGebra können diese Werte anschließend grafisch dargestellt werden, aber auch die zugehörige Wahrscheinlichkeitsverteilung oder die kumulierte Verteilung.

Abb. 6 zeigt die so berechneten Werte $\mathbb{E}_N(T)$ in Abhängigkeit von der oberen Summationsgrenze N . Die horizontale Linie markiert den exakten Erwartungswert $\mathbb{E}(T) = 27$. Die Annäherung macht sichtbar, dass auch seltene späte Treffer noch zum Erwartungswert beitragen. Gerade bei der rechtsschiefen Wartezeitverteilung der Strommaschine wird dadurch deutlich, warum der Erwartungswert nicht allein aus den häufigen frühen Treffern verstanden werden kann.




Abb. 6: Annäherung von $\mathbb{E}_N(T)$ an $\mathbb{E}(T) = 27$ für die Strommaschine. Grundlage sind die in GeoGebra rekursiv berechneten Wahrscheinlichkeiten bis $N = 200$.

6.3 Ausblick: Eine explizite Formel für die Strommaschine

Die Rekursion liefert die Wahrscheinlichkeiten der Strommaschine schrittweise. Ein geschlossener Ausdruck lässt sich erhalten, wenn man die Wörter zählt,

in denen OMA noch nicht vorkommt. Sei $A(n)$ die Anzahl der OMA-freien Wörter der Länge n . Dann gilt

$$S(n) = \frac{A(n)}{3^n}.$$

Damit ist wegen

$$\mathbb{P}(T = n) = S(n-3) \cdot \frac{1}{27}$$

die Verteilung bestimmt, sobald ein Ausdruck für $A(n)$ bekannt ist.

Zunächst betrachten wir Wörter der Länge n , in denen bestimmte OMA-Blöcke ausgewählt werden. Ein ausgewählter OMA-Block belegt drei Stellen. Werden k solche Blöcke ausgewählt, so bleiben $n - 3k$ freie Einzelstellen. Diese freien Stellen sind nicht notwendig OMA-frei; sie gehören lediglich nicht zu den gerade ausgewählten Blöcken.

Kodiert man jeden ausgewählten OMA-Block durch eine 1 und jede freie Einzelstelle durch eine 0, so entstehen Codes mit k Einsen und $n - 3k$ Nullen. Insgesamt haben diese Codes also die Länge

$$k + (n - 3k) = n - 2k.$$

Die k Einsen können daher auf $\binom{n-2k}{k}$ Arten angeordnet werden. Für jede solche Auswahl bleiben $n - 3k$ freie Stellen, die beliebig mit O, M und A gefüllt werden können. Das ergibt den Faktor 3^{n-3k} .

An einem Beispiel kann deutlich gemacht werden, warum nun nicht einfach nur subtrahiert werden darf. Für $n = 9$ liegt zunächst der Ansatz nahe,

$$3^9 - \left(\binom{7}{1} 3^6 + \binom{5}{2} 3^3 + \binom{3}{3} 3^0 \right).$$

Dieser Ansatz ist jedoch falsch: Wörter mit zwei OMA-Blöcken wurden bereits beim Abziehen der einzelnen OMA-Blöcke mehrfach entfernt. Sie müssen daher wieder hinzugefügt werden. Wörter mit drei OMA-Blöcken werden danach erneut falsch gezählt und müssen wieder abgezogen werden. Für $n = 9$ erhält man deshalb

$$A(9) = 3^9 - \binom{7}{1} 3^6 + \binom{5}{2} 3^3 - \binom{3}{3} 3^0.$$

Dies ist der Grundgedanke der Siebformel: zuerst abziehen, dann doppelt Abgezogenes wieder hinzufügen, dann erneut korrigieren.

Allgemein ergibt sich

$$A(n) = \sum_{k=0}^{\lfloor n/3 \rfloor} (-1)^k \binom{n-2k}{k} 3^{n-3k}.$$

Damit gilt

$$S(n) = \frac{A(n)}{3^n} = \sum_{k=0}^{\lfloor n/3 \rfloor} (-1)^k \binom{n-2k}{k} \left(\frac{1}{27}\right)^k.$$

Zusammen mit $\mathbb{P}(T = n) = S(n-3) \cdot \frac{1}{27}$ erhält man damit eine explizite Darstellung der Verteilung der Wartezeit.

6.4 Kenngrößen - schätzen und exakt

Im Unterschied zu den beiden ersten Modellen sind Erwartungswert und Varianz hier im schulnahen Zugang nicht mehr unmittelbar aus einer einfachen geschlossenen Verteilungsformel zugänglich. Die Rekursion liefert zwar exakte Einzelwerte der Verteilung, für die Kenngrößen ist jedoch ein weiterführendes Werkzeug erforderlich. Simulationen mit Python liefern belastbare Schätzwerte und machen die große Streuung des Strommodells sichtbar.

Mit erzeugenden Funktionen kann dieser Schritt auf universitärer Ebene exakt nachgeholt werden. Zugleich lässt sich mit diesem Werkzeug die Normiertheit der Verteilung besonders einfach nachweisen. Eine schulnahe und verständnisorientierte Einführung in erzeugende Funktionen mit ausführlichen Berechnungen zu diesem Modell wird auf GitHub bereitgestellt.

Für die Strommaschine gilt

$$\mathbb{E}(T) = 27, \quad \mathbb{V}(T) = 594, \quad \sigma(T) \approx 24,37.$$

Die große Streuung ist ein zentraler Punkt. Der Erwartungswert 27 bedeutet nicht, dass die Wartezeit typischerweise nahe bei 27 liegt. Lange Wartezeiten gehören zur Struktur der Verteilung.

Für Modell 3 wurden erneut $N = 10\,000$ Durchläufe simuliert. Auf zwei Nachkommastellen gerundet ergeben sich die Schätzwerte $\hat{\mathbb{E}}(T) = 27,04$ und $\hat{\mathbb{V}}(T) = 581,71$. Die Simulation ist im zugehörigen Python-Notebook reproduzierbar dokumentiert.

7 Vergleich der Kenngrößen

Die Kenngrößen machen die Unterschiede der vier Modellierungen besonders deutlich. Während die ersten drei Modelle vergleichsweise kleine Erwartungswerte und Streuungen besitzen, führt die Strommaschine zu einer deutlich größeren Streuung (s. Tab. 1).

8 Fazit

Die Aufgabe „Hol die OMA aus der Socke“ zeigt, wie aus einer einfachen stochastischen Situation ein

Modell	$\mathbb{E}(T)$	$\mathbb{V}(T)$	$\sigma(T)$
1: Spiel ggf. wiederholen	6	30	$\sqrt{30}$
2: Passendes bleibt liegen	6	8	$\sqrt{8}$
3: Strommaschine	27	594	$\sqrt{594}$
4: Zurücklegen (GitHub)	9	18	$\sqrt{18}$

Tab. 1: Kenngrößen der vier Wartezeitmodelle

reichhaltiger Modellierungsprozess entstehen kann. Gerade weil das Ausgangsexperiment anschaulich und handlungsnah ist, lassen sich unterschiedliche Modellannahmen bewusst vergleichen: Wird zurückgelegt? Wird ein passender Buchstabe behalten? Oder entsteht ein fortlaufender zufälliger Buchstabenstrom?

Die vier Wartezeitmodelle führen zu verschiedenen Verteilungen und Kenngrößen. Damit wird sichtbar, dass nicht die Rechnung am Anfang steht, sondern die Modellentscheidung. Erst aus ihr ergeben sich Zustandsgraphen, Rekursionen, Verteilungen und Erwartungswerte.

Digitale Werkzeuge übernehmen dabei unterschiedliche Rollen. GeoGebra macht einzelne Realisationen, Daten und rekursive Berechnungen sichtbar; Python ermöglicht reproduzierbare Simulationen mit großen Stichproben; CAS-Werkzeuge können technische Summen- und Grenzwertberechnungen übernehmen. Entscheidend bleibt jedoch die mathematische Deutung der jeweiligen Ergebnisse.

Die Leuchtturmaufgabe verbindet damit elementare Zugänge mit weiterführenden Ideen. Sie zeigt exemplarisch, dass auch universitäre Konzepte wie Rekursionen, Zustandsmodelle, erzeugende Funktionen oder Siebformeln auf schulnaher Ebene anklingen können, ohne den Unterricht zu überfrachten. Der Kern liegt nicht darin, jede Formel vollständig herzuleiten, sondern darin, Modellieren, Simulieren, Berechnen und Reflektieren als zusammenhängenden stochastischen Denkprozess erfahrbar zu machen. Der Weg führt dabei vom Experiment zur Struktur.

Literatur

- Rierner, W. (2023). *Statistik unterrichten: Eine handlungsorientierte Didaktik der Stochastik*. Kallmeyer.
- Vehling, R. (2026). *Hol die OMA aus der Socke: Ergänzende Materialien*. GitHub. <https://github.com/RVeh/oma-aus-der-socke>

Anschrift des Verfassers:

Reimund Vehling
vehling@icloud.com